UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Minería de Textos

Examen 1 · Recuperación y extracción de información



Luis Alfredo Ramírez Maza

Licenciatura en Ciencia de Datos · FES Acatlán

11 de noviembre de 2026

Del discurso al índice invertido

01 Segmentación

200 palabras por ventana

150 palabras de desplazamiento

40 palabras mínimas

02 Ejemplo de postings

Término: huachicol

df = 714

idf = 5.1862

Pasaje	Fecha	Frecuencia
2191_4	2019-02-16	**7**
2232_25	2019-01-25	**7**
2192_5	2019-02-16	**6**

Tokenización, stopwords y stemming en español. Las marcas de interlocutor se conservan como evidencia, pero se excluyen del índice.

BM25 obtuvo el mejor MAP

Comparación de los cuatro métodos



Modelo ganador

Resultados destacados

0.6150

MAP · BM25 con filtro temporal

P@5	**0.76**
P@10	**0.77**

176 juicios humanos de relevancia

Reglas y BETO: dos enfoques complementarios

Detección

Reglas + gazetteers

Patrones de FECHA y MONTO; nombres conocidos de ORG y LOC.

Predicción

BETO (NER neuronal)

Predice PER, ORG y LOC a partir del contexto del texto.

Evaluación oficial · 19 pasajes con entidades

Método	Precisión	Recall	F1
Reglas	0.7245	0.5145	0.6017
BETO	0.6947	0.6594	0.6766
Combinado	**0.6257**	**0.8116**	**0.7066**

Complementaria: 20 pasajes · F1 combinado = 0.7022

Demostración y conclusiones

Consulta de ejemplo · Q3

Refinería de Dos Bocas en Tabasco

01 Consulta y ventana temporal

02 Top-10 de pasajes (BM25)

03 Entidades PER, ORG, LOC, FECHA, MONTO

04 **Tabla de respuesta con citas**

Comando de la demo: make demo Q=Q3

Qué aprendimos

BM25

mejora el MAP frente a TF-IDF.

Fusión

eleva el recall, pero reduce precisión.

Evidencia

una entidad mencionada no prueba una relación.

La credibilidad requiere revisar contexto, no solo extraer nombres y cifras.