UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Estudios Superiores Acatlán · Licenciatura en Ciencia de Datos

Examen 1 — Minería de Textos

Recuperación de pasajes y extracción de entidades en discursos presidenciales

Luis Alfredo Ramírez Maza · Minería de Textos 11 de noviembre de 2026

RESUMEN

Se construyó un sistema que recupera pasajes de discursos presidenciales y extrae entidades con evidencia verificable. Se contrastaron TF–IDF y BM25, cada uno con y sin restricción temporal, usando juicios humanos de relevancia. La extracción combina expresiones regulares, gazetteers y un modelo NER basado en BETO, evaluados con anotaciones Gold independientes. **BM25 con filtro** obtuvo MAP oficial de **0.6150**; la combinación de métodos de extracción alcanzó **F1 oficial de 0.7066**. El sistema conserva la incertidumbre en las respuestas y distingue las menciones textuales de relaciones institucionales, temporales o monetarias no demostradas.

DISCURSOS	PASAJES	CONSULTAS
2,294	**127,739**	**10**
2018–2024	unidad de búsqueda	ocho dadas y dos propias

1 Objetivos y alcance

El objetivo fue recuperar los diez pasajes más pertinentes para cada consulta y responder preguntas sobre personas, organizaciones, lugares, fechas y montos sin perder su procedencia. Se construyó un índice invertido; se evaluaron los rankings sobre **176 juicios humanos** y las entidades sobre **138 anotaciones Gold** en veinte pasajes. Los identificadores, posiciones y offsets de caracteres permiten contrastar cada resultado con el texto fuente.

2 Corpus, limpieza y segmentación

La fuente `carevies/discursos_AMLO` de Hugging Face [4], fijada en la revisión `2c463bb3…44d2e18` (SHA completo en el README), contiene 2,294 transcripciones del 2 de diciembre de 2018 al 30 de septiembre de 2024. La limpieza conserva el orden y asigna identificadores estables; se auditaron duplicados, acotaciones y fechas (tabla 1). Se conservó el texto canónico para las citas y la anotación, mientras la marca de interlocutor se excluyó del cuerpo indexado.

Tabla 1. *Magnitudes de limpieza y segmentación, verificadas en las salidas de H1.*

Operación	Conteo	Parámetro / operación	Valor
Duplicados exactos / próximos	4 / 1	Tamaño de ventana (palabras)	200
Acotaciones retiradas	7,338	Avance entre ventanas (palabras)	150
Fechas reparadas	10	Longitud mínima (palabras)	40
Pasajes conservados	127,739	Ventanas cortas descartadas	63,384

Las intervenciones de reporteros se mantienen; el filtro mínimo descarta el 64.94 % de sus intervenciones cortas, y los reporteros constituyen el 15.53 % de los pasajes conservados. Esto afecta la cobertura de preguntas breves. No se realizó el análisis de sensibilidad opcional de las ventanas.

3 Preprocesamiento e índice invertido

Se aplicaron tokenización, minúsculas, normalización de acentos, *stopwords* en español y stemming sobre el cuerpo del pasaje. La lista de exclusiones adicionales reduce expresiones estenográficas repetidas (*presidente*, *pregunta*, *gracias*). El texto mostrado al evaluador se conserva sin sustituirlo por su forma normalizada: los offsets de entidades

remiten siempre al pasaje original.

El índice asocia cada término con los pasajes donde aparece y su frecuencia $\mathrm{tf}_{t,p}$. Contiene **35,891 términos** y **7,238,490 postings**, con longitud media de **72.21 tokens** por pasaje preprocesado. La frecuencia documental se contrastó con `CountVectorizer`. La tabla 2 muestra cuatro términos y tres postings por término.

Tabla 2. *Ejemplos del índice invertido. Cada elemento es* `pasaje:frecuencia`.

Término	df	idf BM25	Postings de ejemplo
tren	5,261	3.1896	`442_26:13; 387_18:12; 1533_6:12`
vacuna	4,552	3.3343	`840_10:14; 984_47:13; 1010_12:13`
refinería	2,069	4.1227	`162_65:10; 254_70:10; 237_67:9`
huachicol	714	5.1862	`2191_4:7; 2232_25:7; 2192_5:6`

4 Modelos de recuperación

TF–IDF y similitud del coseno

La frecuencia sublineal, el idf suavizado y la normalización ℓ_2 coinciden con las opciones de scikit-learn utilizadas. Una consulta se transforma al mismo espacio vectorial del índice y se ordenan sus pasajes por similitud coseno:

$$w_{t,p} = (1 + \ln \mathrm{tf}_{t,p}) \left[\ln\left(\frac{1+N}{1+\mathrm{df}_t}\right) + 1 \right], \qquad \cos(q,p) = \frac{q \cdot p}{\|q\|_2 \|p\|_2}. \tag{1}$$

BM25 con saturación de frecuencia

BM25 ajusta el peso del término por rareza, frecuencia y longitud del pasaje. Se utilizaron $k_1 = 1.5$ y $b = 0.75$, con términos únicos de la consulta $U(q)$:

$$\mathrm{idf}(t) = \ln\left(1 + \frac{N - \mathrm{df}_t + 0.5}{\mathrm{df}_t + 0.5}\right), \tag{2}$$

$$s(q,p) = \sum_{t \in U(q)} \mathrm{idf}(t)\, \frac{\mathrm{tf}_{t,p}(k_1+1)}{\mathrm{tf}_{t,p} + k_1\left(1 - b + b|p|/\overline{\mathrm{dl}}\right)}. \tag{3}$$

La variante implementada suma uno dentro del logaritmo para mantener pesos positivos; no es idéntica a la implementación estándar de `BM25Okapi` de `rank_bm25` para términos muy frecuentes. Los filtros de fecha se aplicaron con límites inclusivos *antes* de elegir el top-10, sin reentrenar modelos ni reformular consultas.

Alcance léxico. Las expresiones *Dos Bocas / refinería Olmeca* y *AIFA / Santa Lucía* ilustran el problema de los alias. Un modelo con embeddings densos podría explorar paráfrasis, pero no se entrenó ni evaluó en este examen.

5 Evaluación de recuperación y modelo ganador

El *pool* unió los top-10 de los cuatro rankings. El alumno revisó manualmente **176 pares consulta–pasaje**: 113 se juzgaron relevantes y 63 no relevantes. La fecha no determina el juicio temático. La evaluación original calcula precisión en los cinco y diez primeros lugares, AP@10 y promedio de precisión media (MAP). El denominador R_q corresponde a los relevantes del pool para cada consulta, incluso si no aparecen en su top-10:

$$P@k = \frac{1}{k}\sum_{r=1}^{k} \mathrm{rel}(r), \qquad AP@10 = \frac{\sum_{r=1}^{10} P@r\, \mathrm{rel}(r)}{R_q}, \qquad MAP = \frac{1}{10}\sum_{q=1}^{10} AP_q. \tag{4}$$

Tabla 3. *Resultados IR: evaluación oficial y auditoría temporal complementaria (*).*

Variante	P@5	P@10	MAP	P@5*	P@10*	MAP*
BM25 con filtro	**0.7600**	**0.7700**	**0.6150**	0.7600	0.7700	0.6622
BM25 sin filtro	0.7600	0.7500	0.5922	0.6000	0.6200	0.5288
TF–IDF con filtro	0.6600	0.5800	0.3998	0.6600	0.5800	0.4517
TF–IDF sin filtro	0.6800	0.6000	0.4131	0.5600	0.5000	0.3593

La evaluación oficial determina la selección. La vista complementaria (*) considera no relevantes, para su propia auditoría, los pasajes fuera de la ventana y modifica el denominador; no sustituye las 176 etiquetas originales. BM25 con filtro obtuvo **MAP 0.6150** frente a **0.3998** de TF–IDF con filtro. La regla fijada elegía el mayor MAP entre variantes filtradas (desempate a favor de BM25), pero no hubo empate.

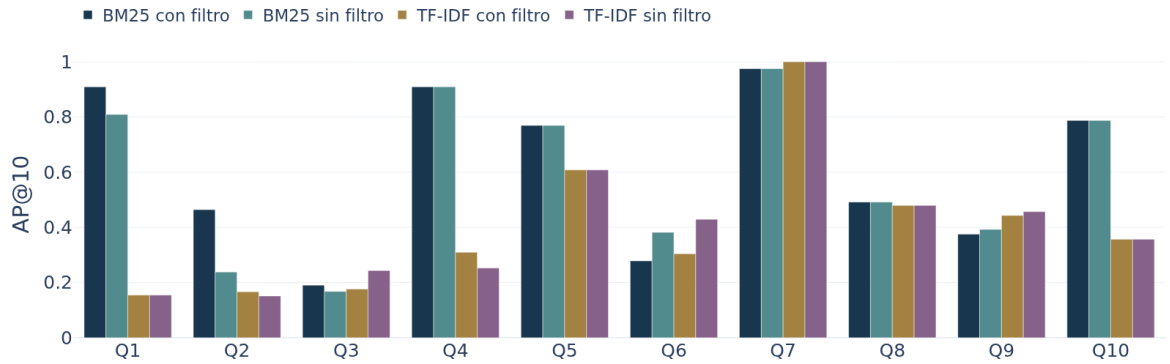


Figura 1. *AP oficial por consulta para las cuatro variantes. Fuente:* `salida/05_ir_por_consulta.csv`.

Las ganancias no son uniformes: BM25 supera a TF–IDF en Q1 (0.9091 frente a 0.1545) y Q4 (0.9094 frente a 0.3095); TF–IDF gana en Q6 (0.3043 frente a 0.2785), Q7 (1.0000 frente a 0.9750) y Q9 (0.4431 frente a 0.3752). Q3 presenta AP bajo en ambos sistemas (0.1762 y 0.1903). Ni la longitud de las consultas (entre cuatro y seis tokens) ni un solo rasgo léxico bastan para explicar por sí solos estas diferencias.

6 Extracción de entidades: reglas y BETO

A partir de los diez pasajes mejor clasificados de cada consulta se buscaron cinco tipos de entidades: **personas (PER), organizaciones (ORG), lugares (LOC), fechas (FECHA) y montos (MONTO)**. Se combinaron dos enfoques. El primero utiliza **expresiones regulares** para localizar fechas y cantidades monetarias, y listas de nombres conocidos (*gazetteers*) para reconocer organizaciones y lugares. El catálogo institucional conservó sus **76 entradas originales**: se examinaron manualmente once propuestas de ampliación, pero ninguna fue aprobada. Cuando dos reglas producen menciones superpuestas, se aplican criterios de prioridad y longitud.

El segundo enfoque emplea **BETO**, un modelo BERT para español ajustado al reconocimiento de entidades [2,3]: `mrm8488/bert-spanish-cased-finetuned-ner`, con revisión fija documentada. A diferencia de las reglas y los *gazetteers*, que **detectan coincidencias mediante patrones o listas predefinidas**, BETO **predice etiquetas** PER, ORG y LOC a partir del contexto; sus intervalos se alinean con el pasaje original. La fusión integra las menciones detectadas por reglas con las entidades predichas por BETO. Cuando ambos métodos coinciden en tipo, inicio y fin, se conserva una sola entidad marcada como *ambos*; los solapamientos parciales se registran por separado. **FECHA y MONTO proceden únicamente de reglas**. Los métodos quedaron fijados antes de evaluar con Gold.

7 Gold y evaluación de extracción

Con semilla 42 se fijaron **20 pasajes únicos**, dos por consulta. El alumno anotó **138 entidades** antes de consultar predicciones y cerró el Gold en Streamlit. El pasaje `1133_87` fue revisado sin entidades. La coincidencia evaluada es estricta: mismo pasaje, tipo e intervalo [inicio, fin). Con verdaderos positivos, falsos positivos y falsos negativos se calculan precisión, exhaustividad y F1:

$$P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN}, \qquad F_1 = \frac{2PR}{P + R}. \tag{5}$$

Tabla 4. *Evaluación IE oficial global sobre los 19 pasajes con entidades Gold.*

Enfoque	Precisión	Recall	F1
Reglas y gazetteers	0.7245	0.5145	0.6017
BETO	0.6947	0.6594	0.6766
Combinado	**0.6257**	**0.8116**	**0.7066**

Tabla 5. *Resultados oficiales por tipo: precisión / recall / F1.*

Tipo	Reglas	BETO	Combinado
PER	0.0000 / 0.0000 / 0.0000	0.2414 / 0.8750 / 0.3784	0.1591 / 0.8750 / 0.2692
ORG	0.7895 / 0.4412 / 0.5660	0.7353 / 0.7353 / 0.7353	0.6829 / 0.8235 / 0.7467
LOC	0.8491 / 0.6000 / 0.7031	0.8676 / 0.7867 / 0.8252	0.7952 / 0.8800 / 0.8354
FECHA	1.0000 / 0.1667 / 0.2857	0.0000 / 0.0000 / 0.0000	1.0000 / 0.1667 / 0.2857
MONTO	1.0000 / 1.0000 / 1.0000	0.0000 / 0.0000 / 0.0000	1.0000 / 1.0000 / 1.0000

El evaluador del kit excluye el único pasaje Gold vacío (19 de 20). La prueba complementaria incluye los veinte y contabiliza sus falsos positivos: **F1 combinado 0.7022**, frente al oficial de 0.7066. El combinado incrementa el recall a 0.8116 con una precisión menor, 0.6257. El F1 perfecto para MONTO se observó solo sobre nueve entidades y no autoriza generalizar el rendimiento.

8 Respuestas por consulta y credibilidad

Las tablas H8 agrupan entidades obtenidas de los diez pasajes principales de BM25 con filtro y las acompañan de identificadores, fechas y extractos verificables. **Una mención no demuestra una relación**: la presencia de una dependencia junto a una obra no acredita responsabilidad, ni una cantidad aislada constituye el costo de un proyecto.

Tabla 6. *Síntesis de las diez consultas, con evidencia y límites de interpretación. Las valoraciones humanas completas permanecen en el repositorio.*

ID	Hallazgo visible	Pasaje [inicio:fin]	Limitación del resultado
Q1	Tren Maya; estados y participantes	`396_23 [796:1230]`	No se recupera un monto directo y completo; varias relaciones siguen ambiguas.
Q2	Vacunas; farmacéuticas y dosis	`1188_80 [393:1022]`	Cifra extraída parcialmente y asociaciones entre actor, fecha y dosis sin confirmar.
Q3	Dos Bocas; Rocío Nahle	`1787_11 [0:259]`	No toda organización mencionada construye la refinería; presupuesto e inversión no equivalen.
Q4	AIFA; Santa Lucía	`1259_59 [0:503]`	Distinguir institución participante, constructora y cifras de costo frente a ahorros.
Q5	Sembrando Vida; Veracruz	`1415_16 [157:657]`	Menciones de estados y montos sin confirmar todas las funciones de operación.
Q6	Huachicol; pérdidas de 65 mil millones	`2115_4 [592:924]`	Mezcla de pérdidas, ahorros y otros gastos; litros y relaciones geográficas incompletos.
Q7	Pensión; 2,550 pesos bimestrales	`2030_1 [548:1131]`	Identificación incompleta de institución pagadora y fecha de aumento.
Q8	Salario mínimo; aumento del 16 %	`1685_4 [805:1161]`	Se confunden porcentajes de distinta naturaleza y faltan actores empresariales.
Q9	Banco del Bienestar; 2,296 sucursales	`347_71 [322:888]`	Sucursales previstas, construidas y operativas no deben sumarse como equivalentes.
Q10	Interoceánico; Salina Cruz	`1272_17 [0:312]`	Inversión parcial sin costo total; fecha de reporte no equivale a inauguración.

Corrección de lectura en Q2. El fragmento *«383 mil 375 dosis»* no debe interpretarse aisladamente como cantidad total: en la revisión de las evidencias se identificó la expresión más amplia *«11 millones 383 mil 375 dosis»*. La tabla H8 original se conserva como resultado del sistema; aquí se documenta el truncamiento en lugar de validarlo.

BALANCE H8 451 filas: **126** respaldadas en texto, **322** ambiguas y **3** sin evidencia suficiente.

El estado *respaldado en texto* indica correspondencia con el corpus, no veracidad externa. Las diez valoraciones del alumno se mantienen completas en `anotaciones/valoraciones.yaml`; no se sustituyen por inferencias redactadas automáticamente.

9 Errores, discusión y conclusiones

Errores auditados en extracción

La coincidencia estricta de spans revela errores concretos. En `1458_12` se fragmenta *Istmo de Tehuantepec* (Gold `[377:397]`); en `326_25` se omite *SEDENA* `[73:79]`. En `228_7`, la regla marca como LOC *Corredor Interoceánico del Istmo de Tehuantepec* `[340:387]`, mientras el Gold cerrado consigna ORG: la discrepancia se mantiene sin revisar retrospectivamente la anotación. En `1277_28`, la expresión *SERVIDORA DE LA NACIÓN* `[17:39]` genera un falso PER en la marca del interlocutor. Estas observaciones identifican fallas, pero no prueban que las mayúsculas sean su causa única.

El posproceso auditado `2-vacios-auditados` elimina solo spans vacíos después de recortar signos y espacios. El disparador fue una comilla predicha como LOC en `1812_0 [945:946]`. Se conservaron las cachés originales y el estado congelado. La versión previa abortó sin F1 completo; el análisis adicional de las transformaciones reportó F1 de modelo crudo **0.5292**, recorte sin unión interpalabra **0.6667** y versión final **0.6766**, sin utilizarlos para escoger parámetros retrospectivamente.

Discusión y conclusiones

Para este corpus y este protocolo, **BM25 con filtro fue la mejor variante según MAP oficial**, aunque TF–IDF superó a BM25 en consultas particulares. En IE, la fusión de reglas y BETO mejoró la exhaustividad respecto a los sistemas individuales, a costa de menor precisión. La diferencia entre F1 oficial (0.7066) y complementario (0.7022) demuestra que la definición del conjunto evaluado importa incluso cuando se conserva el mismo Gold.

El límite más importante de las respuestas no es solo detectar nombres: es **vincular entidades con hechos específicos**. Un monto puede indicar costo, ahorro o presupuesto; una organización puede aparecer en un discurso sin ser responsable de la obra; una fecha del discurso puede no ser la fecha del evento. Las 322 filas ambiguas y las valoraciones humanas muestran por qué la trazabilidad debe acompañarse de cautela interpretativa. La muestra Gold de veinte pasajes y el carácter léxico de los modelos limitan la generalización.

10 Reproducibilidad, autoría y referencias

El repositorio documenta descarga del corpus, dependencias, parámetros, revisiones y hashes. En una comprobación con entorno y cachés vacíos se reconstruyeron corpus, índice y rankings, y **55 CSV coincidieron exactamente**, incluidos los seis archivos oficiales. El entorno se fija mediante `uv.lock`; el README describe los comandos para reproducir las salidas y ejecutar Streamlit.

Uso de IA. Claude Code y Codex asistieron en programación, pruebas, herramientas, generación de tablas y elaboración del borrador. El alumno efectuó los juicios de relevancia, la anotación Gold, la revisión de gazetteer y las valoraciones de credibilidad. Esta revisión editorial y maquetación del informe contó además con ChatGPT. Los auxiliares humanos no se sustituyeron por etiquetas generadas automáticamente.

[1] Robertson, S. y Zaragoza, H. (2009). *The Probabilistic Relevance Framework: BM25 and Beyond*. Foundations and Trends in Information Retrieval, 3(4), 333–389. DOI: 10.1561/1500000019.

[2] Devlin, J. et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL–HLT, 4171–4186. `https://aclanthology.org/N19-1423/`.

[3] Cañete, J. et al. (2020). *Spanish Pre-Trained BERT Model and Evaluation Data*. PML4DC, ICLR.

[4] carevies. `discursos_AMLO` (Hugging Face); modelo NER `mrm8488/bert-spanish-cased-finetuned-ner`. Revisiones y contratos: README y PRD v3.0.